



原创研究

基于EEG的机器人康复运动意图检测： 评估分类和回归算法

阿卜杜勒·马南·汗^{1,6} · 法蒂玛·汗² · 安舒·库马尔·德维迪³ · 维杰·巴斯卡·塞姆瓦尔⁴ · 谢什卡拉·玛莎⁵ ·
维什瓦纳斯·比贾尔万⁵

收到日期:2024 年 3 月 31 日 / 接受日期:2024 年 10 月 14 日
© 作者,根据 Springer Nature Singapore Pte Ltd. 2024 的独家许可

抽象的

通过在康复任务中提供顺从性援助,康复机器人在恢复中风幸存者失去的运动功能方面表现出显著的功效。然而,准确了解受试者的期望运动意图 (DMI) 是提供有效机器人援助的重大挑战。这项工作旨在通过使用脑电图 (EEG) 信号分析上肢运动来确定顺从机器人援助的期望运动意图 (DMI)。一组 15 名身体健康的人进行了六种不同的锻炼。这些动作使用决策树、随机森林和深度学习算法进行分类。使用深度学习,我们实现了最高的准确率,运动到运动分类达到 82%,运动到休息分类达到 90%。随机森林方法在回归测试中比其他算法取得了更好的性能,准确率为 83%。结果证明了我们提出的基于 EEG 的分类和回归技术在检测 DMI 以用于康复机器人辅助方面的有效性。这项研究的样本量很小,仅涉及健康受试者,这是一个需要考虑的关键因素。这可能会限制结果的普遍性,特别是当考虑到运动障碍人群时。然而,尽管存在这一限制,这项研究仍为基于 EEG 的模型在实时康复应用中的潜力提供了宝贵的见解。

关键词脑电信号 · 期望运动意图 · 康复 · C-RNN · 机器学习 · 深度学习

介绍

机器人康复已成为帮助中风、脊髓损伤和脑瘫等神经系统疾病患者康复的关键技术。

这些辅助系统利用先进的控制机制,在身体活动期间提供精确、适应性强的支持

治疗。康复和辅助机器人中的顺从控制在用户的舒适度和舒适度方面起着至关重要的作用。提供适当顺从性的一大问题是测量人类意图。如果没有正确测量人类的期望运动意图 (DMI),现有的顺从控制就无法正确容忍运动并相应地提供帮助。脑电图 (EEG) 是一种非侵入性

* Vishwanath Bijalwan
vishwanathbijalwan@ieee.org

阿卜杜勒·马南·汗
Yf23868@bristol.ac.uk

法蒂玛汗
fatima671990@outlook.com

安舒·库马尔·德维迪
anshucse.dwivedi@gmail.com

维杰·巴斯卡·塞姆瓦尔
vsemwal@manit.ac.in

玛莎·谢什卡拉
marthakala08@gmail.com

¹ 布里斯托大学航空航天工程系,
英国布里斯托尔
² 国家癌症科学与政策研究生院
韩国—山癌症中心
³ 计算机科学与工程与技术学院,
印度大诺伊达贝内特大学
⁴ 印度博帕尔 Maulana Azad 国立科技学院 CSE 系
⁵ 计算机科学与人工智能学院,SR
瓦朗加尔大学,瓦朗加尔,印度
⁶ 电气电子工程系,
英国伦敦西伦敦大学

一种监测大脑活动的方法,通过捕捉与运动意图相关的电信号,在弥补这一差距方面显示出巨大的潜力。这些信号可以被处理来直接控制机器人康复系统,增强它们的响应能力和个性化适应性。因此,DMI 的估计至关重要。康复和辅助机器人的期望运动意图 (DMI) 可以使用生物或非生物传感器来估计[1-3]。许多作者研究了非生物的 DMI 估计[4-7]。在本研究中,我们专注于基于生物的脑电图 (EEG) 传感器来估计 DMI,因为它们具有宝贵的优势。研究发现,基于 EEG 的辅助机器人实现了

回收率高于传统方法[8-12]。研究表明,通过基于脑电图的康复,可以实现改进的 Fugl-Meyer 运动评估 (FMMA) [13],其中 FMMA 代表受试者控制其运动的能力。

基于脑电图的康复的主要挑战是检测受试者的运动想象 (MI)以执行给定任务[14-17]。为此,已经研究了许多特征提取算法。这些算法包括公共空间模式 (CSP) [13]、线性判别分析[18]、支持向量机[19]、卷积神经网络[20, 21]和卷积循环神经网络 (C-RNN) [22, 23]。在[18]中,重点仍然放在基于线性判别分析的分类上,这是一种非常基本的分类方法[24]。该方法以降低 (输入数据的)维度而闻名。公共空间模式可有效用于对运动意象进行分类。

另一方面,缺点是它高度依赖于频带。这限制了它的应用,因为它需要很宽的频带

每个人都有不同的看法[25],这非常不方便。

在文献中,上述文献[14-16]支持向量机和深度学习、卷积神经网络、卷积循环神经网络等都致力于开发新的分类算法,但这些算法要么准确率只能达到59%,要么在有限的应用中进行了测试 (表1)。

此外,机器学习算法通常更适合基于脑电图的实时运动意图检测。

与需要大量处理能力和时间的深度学习模型相比,实时机器学习 (DMI) 具有较低的计算复杂度和更快的训练时间。实时应用程序需要快速响应,而传统的机器学习方法 (如支持向量机 (SVM) 或决策树)可以实现这一目标,而无需像 CNN 和 LSTM 等深度学习模型那样产生大量计算开销。

在本文中,我们提出了一种估计 DMI 的算法。在第一阶段,我们将运动与其他类别区分开来。在进一步评估中,我们将运动类型归类到其他运动类别中 (共有六个运动类别,即时部屈曲/伸展、前臂旋后/旋前和手张开/闭合)。在预测所需的运动类别后,我们使用回归器来估计所需的运动 (就关节角度而言)。使用深度学习、决策树和随机森林方法评估了该算法。在二元分类中,即运动与静止类别,几乎所有方法都达到了90%

准确率。在区分运动类型方面,深度学习算法的表现优于决策树和随机森林。最后,随机森林回归的准确率达到了约85%

预测合适的类别后的准确率。我们用于模型的数据来自BNCI 2020网站[33]。

表1一些主要的基于EEG的运动意图检测算法及相关文献总结

参考	方法论	结果	贡献
塞尔奎泰利等人。(2023) [26]	机器学习在计算机网络中的集成	网络效率和可靠性显著提高	强调机器学习改变网络管理的潜力
Ang 等人 (2012 年) [27]	引入滤波器组 CSP 脑电特征提取	在运动想象任务中实现更高的分类准确率	改进的运动想象脑机接口特征提取方法
Tabar 等人 (2017 年) [28]	使用 CNN 进行自动特征提取和分类	在运动想象分类方面优于传统方法	证明了深度学习对脑电信号分析的功效
Craik 等人 (2019 年) [29]	深度学习技术在脑电图数据中的应用综述	确定深度学习的主要趋势和未来方向	全面回顾 BCI 深度学习的最新进展
Lawhern 等人 (2018 年) [30]	用于实时脑电图分类的轻量级 CNN 的设计	以较低的计算成本实现较高的准确率	为实时 BCI 应用提供实用解决方案
Schirrmeister 等人 (2017 年) [31]	使用 CNN 解码各种 EEG 模式	在多项任务中比传统方法有更好的性能	推进 CNN 在基于 EEG 的 BCI 中的应用
何等 (2010) [32]	开发自适应脑电图集成分类器信号	提高非平稳环境下的适应性和准确性	增强脑电图分类的稳健性 动态环境中的情况

所有结果都是在 0.097 秒后获得的。
回归之后应用了平滑滤波器。

对拟议研究的贡献

·提高运动分类的准确性:研究表明,深度学习算法显著提高了使用脑电信号对不同上肢运动进行分类的准确性,准确率达到了 82%。

·有效的运动与休息分类:能够使用深度学习在区分运动与休息方面实现 90% 的准确率;拟议的研究确保有效识别何时需要机器人协助。

·卓越的回归性能:使用随机森林算法进行回归任务,以 83% 的准确率预测所需的运动意图,有助于机器人辅助的响应调整。

·算法的综合分析:本研究对决策树、随机森林和深度学习算法在分类和回归任务中的有效性进行了综合评估。

研究的新颖性

本研究采用深度学习算法分析机器人康复的脑电图信号,超越了传统方法。我们纳入了六种不同的上肢运动,以增强运动意图检测。我们的方法解决了回归(运动意图的定量预测)和分类(运动与运动和运动与休息)。使用由十五名健康受试者生成的强大数据集,我们为未来涉及运动障碍患者的研究奠定了基础,最终改善了机器人康复系统。

问题陈述

我们的目标是将问题陈述形式化为
基于EEG的运动意图检测在机器人康复中的应用
重点是分类和回归任务。这需要通过使用脑电图(EEG)信号精确检测和预测运动意图,从而提高机器人康复系统的功效。

分类问题

令 $X \in \mathbb{R}^{n \times m}$ 为脑电图特征矩阵,其中 n 为样本数量, m 为提取的特征数量

来自EEG信号。令 $y_c \in \{1, 2, \dots, k\}$ 为不同运动之间的运动分类的类标签向量,其中 k 是不同运动的数量。

对于运动与运动分类问题,我们的目标是找到一个函数 $f_c: \mathbb{R}^m \rightarrow \{1, 2, \dots, k\}$,将 EEG 特征向量映射到相应的运动类别。

目标是最大化分类准确率,定义为:

准确度 $c = \frac{1}{n} \sum_{i=1}^n (f_c(X_i) = y_{c,i})$

其中 (\cdot) 是指示函数,如果参数为真则等于 1,否则等于 0。

对于运动与静止分类问题,设 $y_r \in \{0, 1\}$ 为二元向量,表示样本对应于静止 (0) 还是运动 (1)。我们的目标是找到一个函数 $f_r: \mathbb{R}^m \rightarrow \{0, 1\}$,将 EEG 特征向量映射到静止或运动类别。目标是最大化分类准确率,定义为:

准确度 $r = \frac{1}{n} \sum_{i=1}^n (f_r(X_i) = y_{r,i})$

回归问题

对于回归任务,令 $X \in \mathbb{R}^{n \times m}$ 为 EEG 特征矩阵, $y_g \in \mathbb{R}^n$ 为连续值向量,以某种定量形式(例如运动轨迹或力量)表示期望运动意图 (DMI)。我们的目标是找到一个函数 $g: \mathbb{R}^m \rightarrow \mathbb{R}$,将 EEG 特征向量映射到相应的 DMI 值。目标是最小化均方误差 (MSE),定义为:

均方误差 $= \frac{1}{n} \sum_{i=1}^n (g(X_i) - y_{g,i})^2$

数学问题陈述摘要

1.运动与运动分类:

最大限度 $\frac{1}{n} \sum_{i=1}^n (f_c(X_i) = y_{c,i})$

2.运动与休息分类:

最大限度 $\frac{1}{n} \sum_{i=1}^n (f_r(X_i) = y_{r,i})$

3.期望运动意图 (DMI)的回归:

分钟 $\frac{1}{n} \sum_{i=1}^n (g(X_i) - y_{g,i})^2$

基于脑电图的运动意图检测是机器人康复的一个重要研究领域,对医疗保健和患者康复具有重要意义。通过在康复锻炼期间提供量身定制的合规协助,康复机器人在帮助中风幸存者和运动障碍患者恢复失去的功能方面表现出了巨大的潜力。然而,这些机器人系统的有效性在很大程度上取决于准确解读用户的期望运动意图 (DMI)。以下是这个问题至关重要的一些关键原因:通过准确检测 DMI 可以实现增强的康复效果,从而实现个性化的机器人辅助。基于脑电图的方法可以实时调整这种辅助,确保能够满足患者的需求。通过自动检测运动意图,可以减少人工监督,使康复过程更加高效和方便。这项研究促进了 BCI 技术的进步,增强了对脑电图信号解读和实际应用利用的理解。最终,这些改进的康复技术可以缩短运动障碍患者的康复时间并提高生活质量。尽管机器人康复取得了重大进展,但仍存在一些研究空白:

基于脑电图的运动意图检测的局限性

大多数研究都依赖于传统的机器学习方法,对深度学习的探索有限。它们通常只关注狭窄的运动范围,缺乏实时适应,并且对不同算法的比较分析不足。此外,许多研究没有包括健康和运动障碍受试者的多样化数据集。

目标

本研究的目的是评估深度学习算法在从脑电图信号中识别运动意图方面的有效性,并将其性能与传统机器学习技术进行对比。它将对上肢运动进行分类以促进机器人康复,并通过脑电图分析研究机器人辅助的实时适应性。该研究还将评估机器学习算法 (如决策树、随机森林和深度学习) 在分类和回归任务中的表现。这将使用 15 名健康受试者的数据集来完成,从而为未来涉及运动障碍患者的研究奠定基础。

方法论

人体运动意图对于驱动上肢辅助外骨骼至关重要。如果正确估计,则可以实现顺从运动。在现有方法中,脑电图 (EEG) 信号不需要手术,可用于严重受伤的受试者。考虑到这一潜在应用,本研究专注于使用 EEG 信号进行 DMI 估计。为此,我们使用了 BNCI 2020 竞赛的数据集[18, 33]。以下小节将进一步描述本研究和范例,以估计 DMI。

主题

在这项研究中,我们招募了十五 (15) 名健康受试者。所有受试者的年龄在二十二 (22) 岁至四十 (40) 岁之间,平均年龄为二十七 (27) 岁,标准差为五 (05) 岁。这些受试者因参与研究而获得报酬[33]。此外,该研究还获得了格拉茨医科大学伦理委员会的批准[33]。

实验设置

受试者坐在安乐椅上。他们的右臂连接到上肢外骨骼上。外骨骼被编程为通过受试者的身体质量来抵消重力效应,以便受试者可以感到舒适并且不会感到肌肉疲劳。图 1 显示了用于捕捉脑波活动的 61 通道脑电图中的电极位置。在图 2 中,受试者执行所需的运动意图。每个受试者的运动执行 (ME) 数据是在单个会话中收集的。要求所有受试者执行六种类型的动作。这些动作包括肘部屈曲/伸展、前臂旋前/旋后和手张开/闭合。右上肢在运动执行会话中执行所有这些动作。所有

这些动作都是从放松、自然的中立姿势开始的,即小臂伸展至120度,手半张开,拇指位于内侧。

该位置的 EEG 信号被归类为静息状态。

在运动执行 (ME) 环节中,受试者被要求执行持续动作。受试者被显示提示以记录运动执行的 EEG 数据。开始时

会话 (0 秒)结束时,随着哔声的响起,要求受试者将目光集中在十字架上。2 秒后,向受试者提供提示,要求他们执行给定的任务 (例如六种动作之一,即肘部屈曲/伸展、腕关节旋前/旋后,或手部张开/闭合)。在每次试验结束时,受试者被要求移动他们的

图 1 61通道EEG电极定位


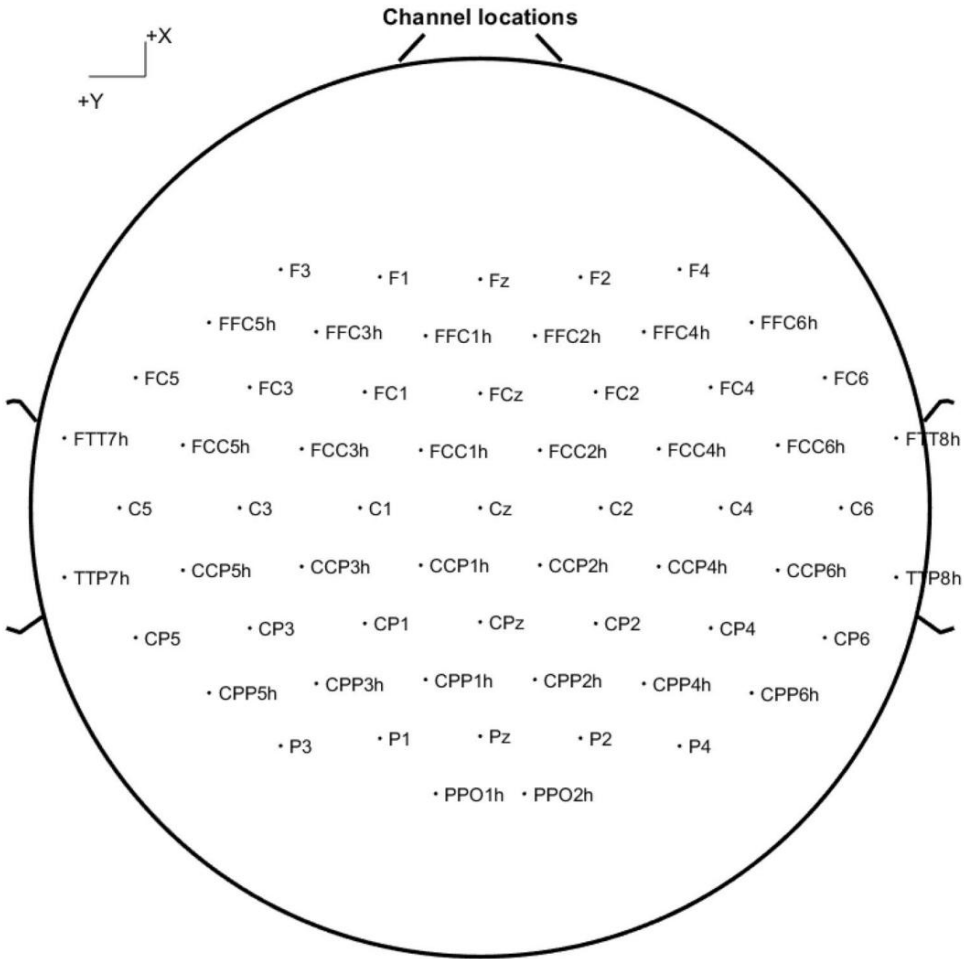


图 2受试者在受控实验室环境中执行期望的运动意图

手臂恢复到初始状态。在每个环节中,记录单个受试者的 10 次运行。每次运行包含 42 次试验。

本研究记录了六 (06) 个运动类别 (肘部屈曲/伸展、腕关节旋后/旋前或手部张开/

测试结果与班级其他成员的测试结果相似。每个班级收集了六十 (60) 次试验的数据。

通过标准化的指导使动作标准化,然后进行 15 分钟的放松,然后练习 5 分钟的目标动作。此外,还通过运动学监测装置跟踪动作,以确保速度和动作符合给定的方式。跟踪此动作后,分析每个任务的速度和指定时间内的轨迹。关于数据可重复性,所有受试者的基线脑电图均在放松状态下记录。

所有 EEG 数据和相关练习都遵循相同的时间段,以相同的顺序执行每个任务,以确保一致性。

数据集收集

脑电图信号由一个包含有源电极和四个 16 通道放大器的 61 通道耳机 (奥地利 g.tec medical engineering GmbH) 测量。这些电极被放置在受试者头部的颞部、中央、顶叶和额叶区域。这些传感器在头部的位置如图 1 所示。右乳突

被用作参考 (AFz 上的地面)。为了滤波 EEG 信号,采用了 8 阶切比雪夫带通滤波器 (从 0.01 到 200 Hz),采样率为 512 Hz。使用 50 Hz 的陷波滤波器来抑制电力线干扰。为了确保受试者之间的运动一致性,指示所有参与者按照标准化的视觉提示执行预先定义的运动想象任务 (例如,想象手抓握)。选择这些动作是为了最大限度地减少受试者之间的差异。此外,所有 EEG 数据都经过预处理,通过对每个受试者的 EEG 信号应用 z 分数标准化来标准化受试者之间的信号幅度,确保基线 EEG 活动的个体差异不会影响分类和回归分析。

动作识别

为了识别运动执行 (ME) 会话中的各种动作,从测角仪和数据手套收集传感器数据。对于肘部伸展/屈曲和前臂旋后/

分别使用了内旋、肘部和腕部传感器。
对于手的张开/闭合,使用从手套收集的数据。使用主成分分析 (PCA) 来减少从手套获得的尺寸。仅使用第一个主成分进行进一步处理。

传感器数据与前一个时间平均值之间的绝对差异定义了一次移动。如果此差异超过某个阈值,则认为已执行了移动 (每个传感器的阈值是根据最小化误报检测而定义的)。

预处理

采用带通滤波器 (0.3~70 Hz)对EEG信号原始数据进行4阶零相位巴特沃斯滤波器滤波,并采用陷波滤波器抑制不需要的50 Hz工频干扰。

处理过的数据会去除伪影。为此,分别标记了 (1) 高于/低于阈值 - 200 μ V 和 200 μ V 的值。此外,还突出显示了具有异常联合概率和异常峰度的试验。为了标记这些异常,使用了阈值 (该阈值是这些试验静态值标准偏差的五 (05) 倍)。在丢弃受伪影污染的试验之前,先找到一个平均参考。为此,使用零相位四阶巴特沃斯带通滤波器 (0.3-3.0 Hz) 过滤未过滤的数据。然后,将过滤后的数据重新参考到标准平均参考。找到重新参考点后,丢弃在之前的方法 (将数据从 0.3 过滤到 70 Hz 的方法)中受伪影污染的试验。

分类

对于动作分析,考虑了两种分类: (1)在第一种分类中,将六 (06) 种动作 (肘部屈曲/伸展、前臂旋后/旋前和手张开/闭合)相互分类, (2)在第二种分类中,将所有六种动作与静止类别进行比较。在本说明书中,第一种分类称为“运动与运动”,而第二种分类称为“运动与休息”。在“运动与休息”分类中,记录的休息类别与汇总动作类别进行分类。此动作类别是通过分离执行动作的特定数据获得的。此分离的数据被标记为动作数据。以同样的方式,收集了六种不同动作的数据。此动作数据已与静止数据混合。

还包括运动和休息的组合数据

用于分类。对于运动对运动的多类问题,我们使用了 1-vs-1 分类策略。它形成了 15 个二元类:

- 屈曲与伸展。
- 屈曲与旋后。
- 屈曲与旋前。
- 屈曲与手张开。
- 屈曲与手闭合。
- 伸展与旋后。
- 伸展与内旋。
- 延伸与手张开。
- 伸展与手闭合。
- 外翻与内翻。
- 旋后与张开手。
- 旋后与手闭合。
- 内旋与手张开。
- 内旋与手闭合。
- 张开手与握紧手。

对于分类,我们使用了不同的 0.2 秒时间窗口。为了验证分类,我们使用了 10 \times 10 倍交叉验证。

用于估计期望运动意图的机器学习

经过预处理和过滤,我们提取了人体运动意图估计。图 3显示了使用运动意图估计的辅助/康复外骨骼的概念流程图。算法 1 描述了基于 EEG 的运动意图的工作原理。图 4和图5分别是使用 ELM 和 RBFNN 方法的 DMI 表示。




图 3首先,训练三个模块。这些模块分别是 (1) 运动与静止、(2) 运动与运动和 (3) 回归。运动与静止模块会判断输入数据是否属于运动类。如果属于运动类,运动与运动模块会找到相关类。找到相关类后,回归模块会预测所需的运动意图。该算法已在算法 1 中进行了解释

算法1运动意图估计算法



分类与回归

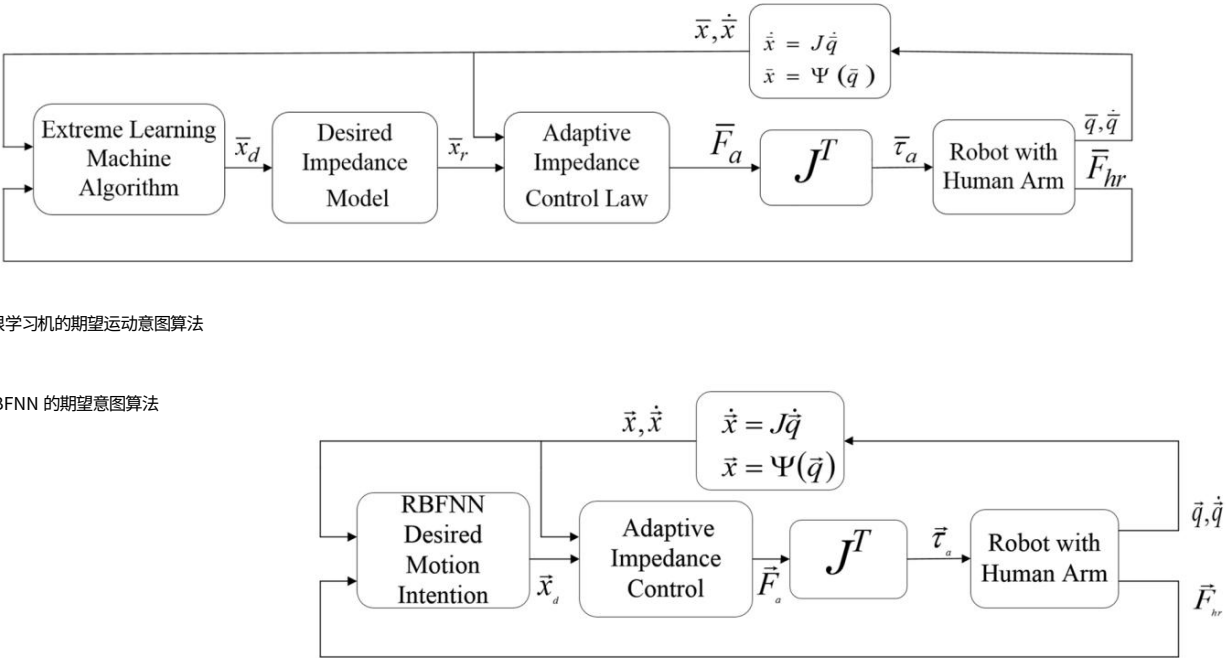
对于分类,我们使用了决策树[34]、随机森林[35]和深度学习[36, 37]技术。下面简要介绍一下所采用的技术。

决策树算法[34]

决策树是使用递归程序实现的。此递归程序优化了数据集中的分离。它是通过将根节点划分为两个或多个子节点来实现的。重复此过程,直到满足终止条件。对于基于 EEG 的分类,我们使用此方法来区分各种运动。我们为此目的采用了[34]。它的优势在于数据集具有连续

图4基于极限学习机的期望运动意图算法

图 5使用 RBFNN 的期望意图算法



属性。分类后,我们使用相同的技术进行回归。使用回归,我们估计了期望运动意图 (DMI)。

神经网络[24]

随机森林算法[35]

随机森林是决策树方法[35]的改进变体。它不使用单棵树,而是使用多棵树来学习相同的输出。这被称为集成学习。当不同类别在数据集中存在不平衡时,这种方法是有益的。此方法有利于处理这些不平衡。其性能良好的另一个原因是它的并行架构。这种并行架构有助于更快地训练模型。随机森林方法的准确性主要取决于树的数量[38]。一般来说,树的数量越多越好。然而,在达到特定数量的树之后,其性能并没有提高[39]。对于优化分类,我们使用了[35]方法。该方法有效地去除了不必要的分类树 (表 2.3)。这有助于快速训练模型。同样的方法已经得到进一步扩展

深度学习或神经网络是具有许多隐藏层的多层感知器 (MLP) 集。神经网络可以使用这些层来学习复杂模型,无需人工干预。它只需要训练数据和时间来学习模型。深度学习包含更深的神经连接。这些更深的神经连接极大地提高了神经网络的学习性能。在本研究中,我们使用神经网络进行分类和回归[24, 36, 37]。首先,我们研究了分类问题。在确定正确的类别后,我们应用回归来预测正确的期望运动意图。

结果

结果摘要

结果摘要如表 4 所示。在运行算法 0.097 秒后 (即运动开始后第 50 次迭代后)测量准确度。总体而言,所有算法 (深度学习、决策树和随机森林)在 Mov-vs-Rest 分类中表现良好。对于 Mov-vs-Rest,我们实现了所有算法 90% 以上的准确度。然而,对于 Mov-vs-Mov,深度学习算法的表现优于其他算法。经过

用于回归。要执行回归,请遵循 “决策树”一节中所述的相同协议。

算法”。

表 2随机森林分类器的超参数和架构

类别	范围	值/描述
超参数估计标准		100 (森林中的树木数量;更多的树木可以提高性能,但会增加计算成本)
		“基尼系数” (衡量分割的质量;替代方案包括 “熵”)
建筑学	引导随机状态	False (控制是否使用引导程序;如果为 False,则所有树都使用整个数据集)
		0 (设置随机数生成的种子以实现可重复性)
	集成方法结合多个决策树来提高准确率并减少过度拟合	
	树训练	每棵树都在数据的随机子集上进行训练 (有或没有引导)
	决策过程每棵树都会做出独立的预测;最终的预测基于多数投票 (分类)	或平均值 (回归)

表3人工神经网络的超参数和结构

类别	范围	值/描述
超参数	batch_size	10 (模型更新前处理的样本数)
	nb_epoch	100 (整个训练数据集的迭代次数)
	优化器	‘adam’ (自适应矩估计优化器)
	损失	‘binary_crossentropy’ (用于二元分类问题的损失函数)
建筑学	输入层	61 个输入特征
	隐藏图层	4 个隐藏层,每层 183 个单元,使用 ReLU 激活
	输出层	6 个输出单元,使用 S 型激活 (用于多标签分类)

表 4汇总表显示了 15 名受试者的平均结果及其标准差

算法	分类准确率 % (Mov-vs-Rest)	分类准确率 % (Mov-vs-Mov)	回归准确率 %
深度学习	93.5 ± 1.9	84.5 ± 3.2	75.0 ± 2.5
决策树	92.5 ± 2.1	82.5 ± 3.1	78.7 ± 3.1
随机森林	94.5 ± 1.1	78.2 ± 4.1	82.2 ± 2.1

所有算法在 0.097 秒后（即运动开始后第 50 次迭代）达到最终准确率

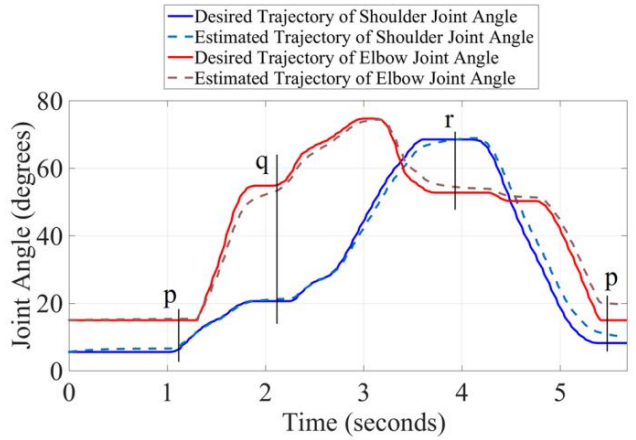


图 6肩关节和肘关节角度随时间变化的期望轨迹和估计轨迹比较

通过分类,我们进行回归以估计 DMI 估计值。从表 4可以看出,随机森林优于其他算法。值得一提的是,这些结果是在对输出回归模型应用平滑滤波器后获得的。每个算法的详细信息已在小节中描述（图 6.7）。

分类结果 混淆矩阵

图8,9,10,11,12和13显示了深度学习、决策树和随机森林的混淆矩阵。

这些混淆矩阵是在平均分类达到其最大限度时获取的。这些混淆矩阵具有相对编号;数字总和为100%。总体而言,深度学习算法在 Mov-vs-Mov 分类中优于其他算法（决策树和随机森林）。从图 9 中对角线的高分可以看出。三种算法在 mov-vs-rest 分类中没有显著差异。

图 10和11分别显示了 mov-vs-rest 和 mov-vs-mov 的决策树混淆矩阵。mov-vs-rest 和 mov-vs-mov 的准确率在可接受范围内。

图 12和13分别显示了随机森林的 Mov-vs-Rest 和 Mov-vs-Mov 的混淆矩阵。Mov-vs-Rest 分类与另一种算法相当。对于 Mov-vs-Mov,尽管混淆矩阵在对角线上仍然具有较高的值,但得分并不比深度学习混淆矩阵好（如图 9 所示）。

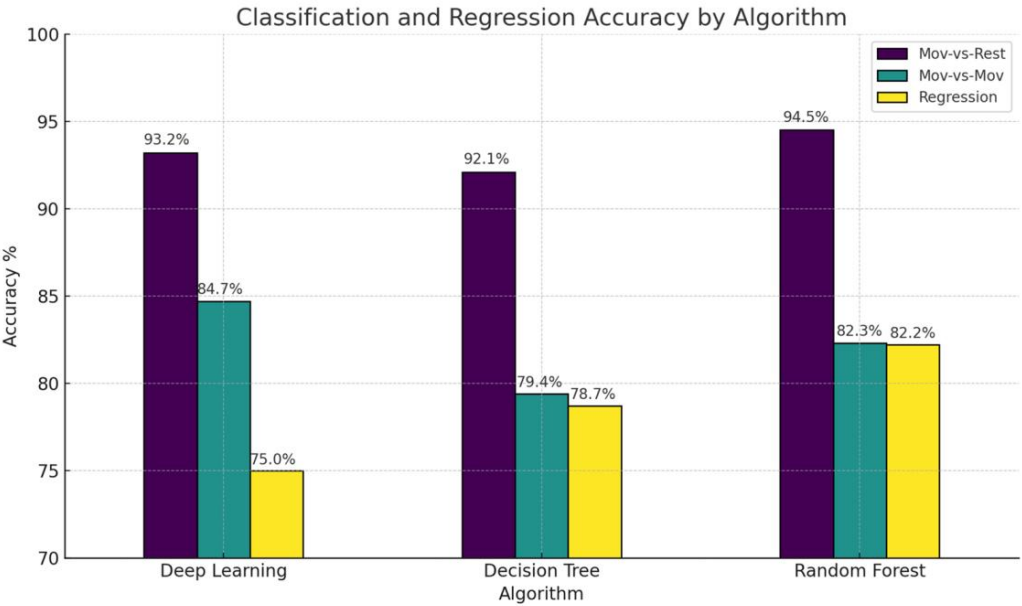


图 7不同 ML 算法的分类和回归准确率百分比

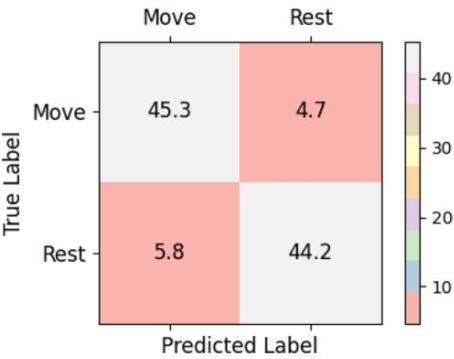


图 8深度学习移动与静止分类混淆矩阵




图 12随机森林对 Mov-vs-Rest 分类的混淆矩阵

Known	Flex	Ext	Sup	Pro	Clo	Opn
	15.2	0.3	0.4	0.6	0.3	0.4
	1.6	11.1	0.2	0.4	0.3	0.2
	2.0	0.3	13.2	0.5	0.3	0.6
	2.1	0.4	0.3	12.9	0.3	0.4
	2.1	0.4	0.7	0.6	12.4	0.4
	2.2	0.4	0.5	0.7	0.4	14.7
		Predicted				

图 9 Mov-vs-Mov 分类的深度学习混淆矩阵

Known	Flex	Ext	Sup	Pro	Clo	Opn
	12.1	0.3	0.3	0.4	0.3	0.4
	1.3	8.9	0.2	0.4	0.2	0.2
	1.6	0.2	10.6	0.4	0.3	0.4
	1.7	0.3	0.2	10.3	0.3	0.3
	1.7	0.3	0.6	0.5	9.9	0.3
	1.7	0.4	0.4	0.6	0.3	11.7
		Predicted				

图 13 Mov-vs-Mov 分类的随机森林混淆矩阵




图 10 Mov-vs-Rest 分类的决策树混淆矩阵

Known	Flex	Ext	Sup	Pro	Clo	Opn
	8.4	1.5	1.8	1.8	1.6	2.0
	1.3	7.0	1.3	1.4	1.1	1.9
	1.6	1.2	8.6	1.7	1.6	1.9
	1.6	1.5	1.9	8.2	1.6	1.9
	1.6	1.4	1.8	1.6	8.5	1.6
	1.9	1.7	2.0	1.8	1.6	10.0
		Predicted				

图 11 Mov-vs-Mov 分类的决策树混淆矩阵




图 14比较箱线图 随机森林回归 (RF-R) 、决策树回归 (DT-R)和神经网络回归 (ANN-R)

回归结果

经过 mov-vs-rest 和 mov-vs-mov 分类后,我们训练了输出角度模型.图 15、17 和19显示了受试者 1 和运行 1 的训练回归模型 (用于深度学习、决策树和随机森林)的结果.图16、18和20显示了所有三种算法的误差图.结果是在 0.097 秒后获得的,即从开始运动开始的第 50 次迭代之后。

平滑过滤器已过滤回归器的输出。图形运动为肘部屈伸运动。回归摘要如图 14 所示。它显示




图 15肘部屈曲/伸展的深度学习回归 (针对受试者 1,运行 1)。角度以度为单位。在输出处应用了平滑滤波器




图 18决策树算法的回归误差 (针对受试者 1,运行 1)。角度误差以度为单位。可以看出,虽然屈曲/延伸动作执行,误差增大




图 16深度学习算法的回归误差 (针对主题 1,运行 1)。角度误差以度为单位。可以看出,虽然屈曲/延伸动作执行,误差增大




图 19肘部屈曲/伸展的随机森林回归 (针对受试者 1,运行 1)。角度以度为单位。在输出处应用了平滑滤波器




图 17肘部屈曲/伸展的决策树回归 (针对子主题 1,运行 1)。角度以度为单位。在输出处应用了平滑滤波器




图 20随机森林算法的回归误差 (针对主题 1,运行 1)。角度误差以度为单位。可以看出,虽然屈曲/延伸动作执行,误差增大

与决策树和深度学习算法相比,随机森林具有最高的准确度。

图 15和16表示深度学习结果。可以看出,在运动过程中误差增加,达到22°。这是因为

所需的关节角度很难确定。因此,存在一些错误;尽管如此,预测的输出点方向是正确的。平均准确率高达75%。

它具有很高的准确性,可以为康复机器人提供合规的援助。

图 17和18表示决策树回归结果。如前所述,深度学习算法的误差趋势类似。在运动过程中,误差增加,最高可达20°。;总体而言,误差变化小于深度学习算法。结果的解释与深度学习类似。决策树回归的输出略优于深度学习。

图 19和20表示随机森林回归结果。与上一个结果一样,误差在运动过程中增加。误差通常保持在10°以下,但有一处误差达到(约) 18°。

从结果可以看出,虽然算法的结果对DMI估计有帮助,但是随机森林的性能优于深度学习和决策树算法。

讨论

从混淆矩阵和回归结果可以看出,所有这些算法对于期望运动意图 (DMI) 估计都非常有效。总体而言,随机森林算法在分类和回归方面的表现优于其他算法。它表明回归模型的输出可以帮助机器人以顺从的方式协助患者。但存在局限性。然而,本研究估计了输出角度,但使用 EEG 信号估计产生的扭矩可能更合适。此外,本研究采用了小样本量,仅包括健康受试者,这可能会限制结果对运动障碍人群的普遍性。未来的研究将扩大样本量,并包括运动障碍患者,以评估这些算法在现实康复场景中的有效性。

结论

在本研究中,我们比较了深度学习、决策树和随机森林算法来估计期望的运动意图,以便康复机器人能够协助

以顺从的方式让患者做运动。为此,我们使用脑电图 (EEG) 信号。我们研究了六种运动类别。这些运动包括肘部屈曲/伸展、前臂旋后/旋前和手张开/闭合。该研究使用了 15 名健康受试者的数据,他们在十 (10) 次运行中执行了这些运动。每次运行中有四十二 (42) 次试验。在过滤 EEG 信号后,我们首先区分了运动与静止类别。如果运动

被检测到,我们估计了所需的运动类别 (肘部屈曲/伸展、前臂旋后/旋前,或手

打开/关闭)。找到所需的运动类别后,我们使用回归模型 (深度学习、决策树和随机森林) 来估计 DMI 的关节角度。对于运动与静止分类,我们使用随机森林分类器实现了平均 94.5% 的准确率。对于运动与运动分类,深度学习算法优于其他算法;我们实现了平均 84.7% 的准确率。此外,回归用于估计所需的运动意图 (DMI)。

对于回归,随机森林回归方法的表现优于其他算法。我们实现了平均82.2%

准确度。这些准确度是在 0.097 秒后实现的,即运动开始后第 50 次迭代。使用平滑滤波器对回归输出进行平滑处理。我们的研究表明,所提出的算法有可能改善康复机器人的柔顺运动辅助,从而提高中风患者的康复率。

基于脑电图的真实世界运动意图检测

康复可以通过个性化康复方案来彻底改变患者护理,这些方案可以根据个人需求进行动态调整。康复机器人可以使用实时脑电图反馈调整其辅助水平,通过互动系统和游戏化练习使康复更具吸引力,鼓励患者在康复过程中积极主动。这种整合还需要脑电图设备的便携性、强大的机器人系统和自适应算法来促进互动。需要培训治疗师进行脑电图数据解释和有效利用上述系统,还需要教育患者了解该技术的优点。

这项研究有几个优点:这是一项新颖的比较研究,研究基于脑电图的运动意图检测中的分类和回归算法,而以前的文献对此还不够。总体而言,结果表明这些技术适用于机器人康复的实时实施,而不同 ML 模型的集成则为这些方法的比较有效性提供了见解。此外,该研究通过展示基于脑电图的系统在受控环境中的可行性,为未来的研究奠定了坚实的基础。然而,概括事物并根据对这一特定交互方面的分析得出结论存在一些缺点,应该提到。参与的受访者人数较少,尤其是没有运动障碍的志愿者,阻碍了将结果扩展到运动功能受损的人群。这是康复研究的重点。然而,实验室的环境条件可能并不总是反映成功康复的实际生活条件。这些因素表明,应该努力扩展研究并在不同的、更现实的环境中测试该方法的可行性,在这些环境中信号质量和实时性能可能会出现更为严重的问题。

作者贡献Abdul Manan Khan:概念化、数据管理、调查、方法、软件、可视化、写作 原始草稿。Fatima Khan:作为医生的医疗援助方法和伦理关注。Vijay Bhaskar Semwal:调查、验证。Anshu Kumar Dwivedi:调查、验证。Sheshikala Martha:调查、验证、写作指导。Vishwanath Bijal-wan:概念化、协调、资源、监督、验证、写作审查和编辑。项目管理。

资金作者没有收到这项工作的特定资金。

数据可用性声明当前研究期间生成和/或分析的数据集可根据合理要求从通讯作者处获取。为数据预处理和模型训练开发的任何特定脚本或代码也可根据要求共享,以便使研究界进行可重复性和进一步分析。请联系通讯作者。

声明

利益冲突作者声明他们没有已知的竞争性财务利益或个人关系,可能影响本文所报告的工作。

参考

1.赵晓玲,楚燕,韩建,张哲.基于Ssvep的脑机接口控制功能性电刺激系统用于上肢康复.《IEEE系统与机器人控制学报》.2016;46 (7) :947-56。

2. Mikulski MA.上肢单自由度动力外骨骼的肌电图控制算法.见:第四届人机系统交互国际会议,HSI 2011.2011 年,第 117-22 页。

3. Gunasekara J,Gopura R,Jayawardane T,Lalitharathne S.上肢外骨骼机器人的控制方法.于:2012年IEEE/ SICE 国际系统集成研讨会 (SII).2012 年,第 19-24 页。

4. Khan AM, Yun DW, Ali MA, Zuhaib KM, Yuan C, Iqbal J, Han J, Shin K, Han C. Passivity based adaptivity control for upper extremity assist exoskeleton. Int J Control Autom Syst. 2016;14(1):291–300.

5. Khan AM,Yun D.Ali MA,Han J.Shin K.Han C.上肢辅助外骨骼的自适应阻抗控制.见:2015 年 IEEE 机器人与自动化国际会议 (ICRA).2015 年,第 4359–66 页。

6. Khan AM,Khan F,Han C. 使用极限学习机估计上肢辅助外骨骼的期望运动意图。参见:2016 年 IEEE 先进智能机电一体化国际会议 (AIM).2016 年,第 919-23 页。

7. Khan AM, Usman M, Ali A, Khan F, Yaqub S, Han C.肌肉周长传感器和基于模型参考的上肢辅助外骨骼机器人自适应阻抗控制. Adv Robot.2016;30(24):1515–29。

8. Ang KK, Chua KSG, Phua KS, Wang C, Chin ZY, Kuah CWK, Low W, Guan C. 基于脑电图的运动想象脑机接口机器人中风康复的随机对照试验.临床脑电图神经科学.2015;46 (4) :310-20。

9. Ang KK, Guan C, Phua KS, Wang C, Zhou L, Tang KY, Joseph Ephraim GJ, Kuah CWK, Chua KSG. 基于脑机接口的机器人末端执行器系统用于腕部和手部康复:慢性中风三组随机对照试验结果。Front Neuroeng.2014;7:30。

10. Bijalwan V,Semwal VB,Singh G,Mandal TK.Hdl-psr:使用混合深度学习方法对中风后康复的时空特征进行建模.神经过程快报.2023;55(1) :279-98。

11. Bijalwan V,Semwal VB,Singh G,Crespo RG.用于受伤后步行模式恢复和姿势稳定性康复运动识别的异构计算模型. Expert Syst.2022;39(6) :e12706。

12. Baek H,Khan AM,Bijalwan V,Jeon S,Kim Y.基于旋转形状记忆合金执行器关节的灵巧机械手.引自: IEEE 医学机器人和仿生学汇刊.2023 年。

13. Suwannarat A, Pan-ngum S, Israsena P. 运动想象训练系统中上肢运动脑电图测量比较. Biomed Eng Online.2018;17(1):103。

14. Yang S, Li M, Wang J. 融合 semg 和 eeg 以提高使用功能连接和 gcn 的手部运动识别的鲁棒性。IEEE Sens J. 2022;22(24):24309–19。

15. Trujillo P,Mastropietro A,Scano A,Chiavenna A,Mrakic-Sposta S,Caimmi M,Molteni F, Rizzo G.定量脑电图用于预测慢性中风机器人辅助康复中的上肢运动恢复。 IEEE 跨神经系统康复工程。 2017;25(7) :1058–67。

16. Osuagwu BA, Zych M, Vuckovic A. 隐性运动意象是脑机接口的可靠策略吗? IEEE Trans Neural Syst Rehabil Eng. 2017;25(12):2239–48。

17. Choi HJ, Das S, Peng S, Bajcsy R, Figueroa N. 基于脑电图的运动意图检测在实时机器人辅助控制中的可行性 [在线] (2024).arXiv :2403.08149

18. Ofner P, Schwarz A, Pereira J, Müller-Putz GR. 上肢运动可从低频脑电图的时间域解码. PLoS ONE.2017;12(8):1–24。

19. Fazli S,Grozea C,Danoczy M,Blankertz B,Popescu F,Müller KR.受试者独立的基于脑电图的 bci 解码.见:Bengio Y,Schuurmans D,Laferty JD,Williams CKI,Culotta A,编辑.神经信息处理系统的进展,卷。

22. Curran Associates, Inc.;2009 年,第 513-21 页。

20. Chaudhary S,Taran S,Bajaj V,Sengur A.基于卷积神经网络的运动想象任务脑电图信号分类方法.《IEEE Sens J. 2019;19 (12) :4494–500。

21. Sain MK,Singha J,Bijalwan V. 使用 myolo-csrt 和 hgcn 进行人机交互的动态手势识别.引自: Sisodia DS,Garg L,Pachori RB,Tanveer M,编辑。

用于数据分析和信号处理的机器学习技术.新加坡:Springer Nature Singapore;2023 年,第 631-42 页。

22. Zhang D, Yao L, Chen K, Monaghan J. 一种用于独立于受试者的脑电信号分析的卷积循环注意力模型.《IEEE 信号处理快报》.2019;26 (5) :715-9。

23. Semwal VB,Kim Y,Bijalwan V,Verma A,Singh G,Gaud N,Baek H,Khan AM.开发适用于人类步态所有子阶段的 lstm 模型和通用多项式方程.《IEEE Sens J.2023 年。

24. Goodfellow I,Bengio Y,Courville A.《深度学习》。麻省理工学院出版社;2016 年。 <http://www.deeplearningbook.org>。

25. Park S,Lee D,Lee S. 滤波器组正则化常见空间模式集成用于小样本运动想象分类。 IEEE Trans Neural Syst Rehabil Eng.2018;26 (2) :498–505。

26. Cerquitelli T 等人.机器学习赋能计算机网络作品. Comput Netw.2023;212:109807。

27. Ang KK,Chin Z,Wang C,Guan C,Zhang H.脑机接口中的滤波器组公共空间模式 (fbcspp).在:IEEE 国际神经网络联合会议.2012 年。第 2390-97 页。

28. Tabar YR,Halici U. 一种用于对脑电图运动想象信号进行分类的新型深度学习方法. J Neural Eng. 2017;14 (1) :016003。

29. Craik A, He Y, Contreras-Vidal JL. 深度学习在脑电图 (eeg) 分类任务中的应用:综述。J Neural Eng. 2019;16(3): 031001。

30. Lawhern VJ,Solon A,Waytowich NR,Gordon S,Hung CP 和 Lance BJ:Eegnet:用于基于脑电图的脑机接口的紧凑卷积神经网络。J Neural Eng. 2018;15(5):056013。

31. Schirrmeister RT,Springenberg JT,Fiederer LDJ,Glasstetter M,Eggensperger K,Tangermann M,Hutter F,Burgard W,Ball T. 利用卷积神经网络进行深度学习,实现脑电图解码和可视化。Hum Brain Mapp. 2017;38(11):5391-420。

32. 何华,吴丹,周胜. 一种用于脑电信号分类的自适应集成学习方法. IEEE Trans Neural Syst Rehabil Eng. 2010;18(5):466–72。

33.Bnci Horizon 2020 数据集。 <http://bnci-horizon-2020.eu/database/>数据集。访问日期:2019 年 8 月 20 日。

34. Yan J, Zhang Z, Xie L, Zhu Z. 连续属性决策树的统一框架。IEEE Access。2019;7: 11924-33。

35. Paul A,Mukherjee DP,Das P,Gangopadhyay A,Chintha AR 和 Kundu S。改进的随机森林分类方法。IEEE 图像处理。2018;27(8):4012-24。

36. Shrestha A,Mahmood A。深度学习算法和架构回顾。IEEE Access。2019;7:53040-65。

37. Humbird KD,Peterson JL,Mcclarren RG。使用决策树进行深度神经网络初始化。IEEE Trans Neural Netw Learn Syst。2019;30(5):1286-95。

38. Fernández-González P,Bielza C,Larrañaga P. 随机森林作为k 个潜在最近邻的加权 和进行回归。 IEEE Access。2019;7:25660-72。

39. Oshiro TM,Perez PS,Baranauskas JA。随机森林中有多少棵树?收录于:Perner P 编辑。模式识别中的机器学习和数据挖掘。柏林:Springer Berlin Heidelberg;2012 年, 第 154-68 页。

出版商注释Springer Nature 对于已出版地图和机构隶属关系中的管辖权主张保持中立。

Springer Nature 或其许可人 (例如学会或其他合作伙伴)根据与作者或其他权利人达成的 出版协议,拥有本文的独家权利;作者对本文已接受稿件版本的自行存档完全受此类出版协议 条款和适用法律的约束。

计算机科学系
A **SPRINGER NATURE** journal